دانشگاه صنعتی امیرکبیر
(پلیتکنیک تهران)

درس تحلیل داده و اطلاعات

پروژه نهایی

امیرمهدی زرین‌نژاد

۹۷۳۱۰۸۷

نیم‌سال اول ۱۴۰۱

سوال۱)

در سوال اول با توجه به اسلایدهای درس عمل می‌کنیم و فرمول و روابط را پیاده‌سازی می‌کنیم:

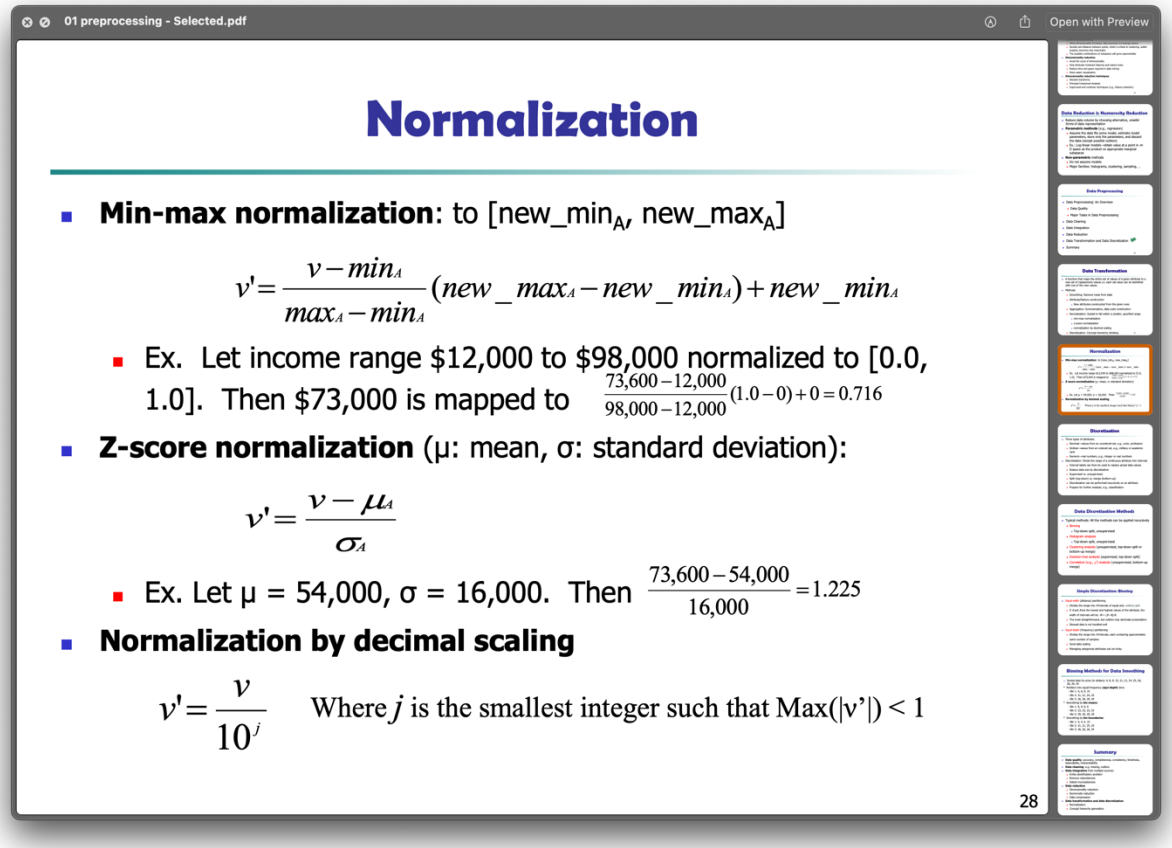

در کد نیز نام‌گذاری‌ها و پرینت‌ها به خوبی و قابل درک انجام شده‌اند.

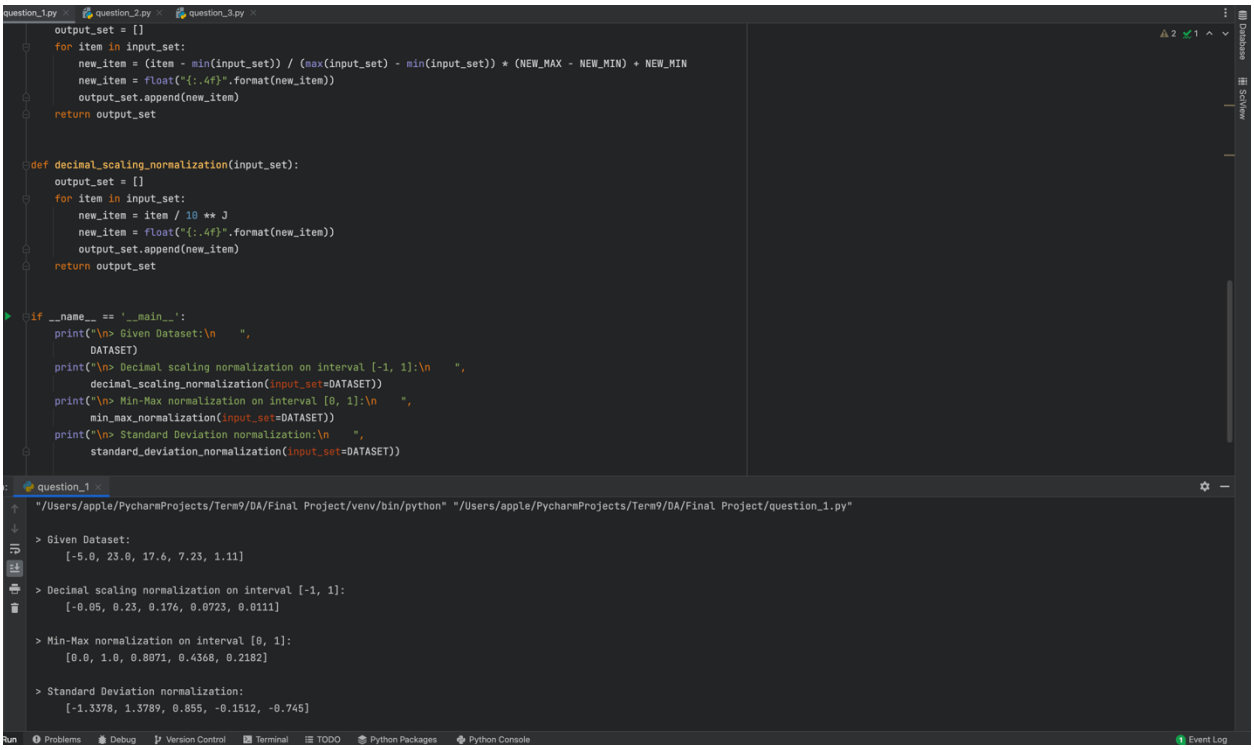

سوال ۲)

در سوال ۲ نیز با فرمول زیر عمل می‌کنیم:

$$\text{Upper limit} = Q3 + 1.5 * (Q3-Q1) = \text{mean} + 2.7 * \text{stdev}$$

$$\text{Lower limit} = Q1 - 1.5 * (Q3-Q1) = \text{mean} - 2.7 * \text{stdev}$$

در کد نیز نام‌گذاری‌ها و پرینت‌ها به خوبی و قابل درک انجام شده‌اند.

همانطور که در نتیجه می‌بینیم، با کاهش ترشهولد از ۳ به ۲، داده(عدد) ۱۵ در دسته داده‌های‌پرت قرار می‌گیرد.

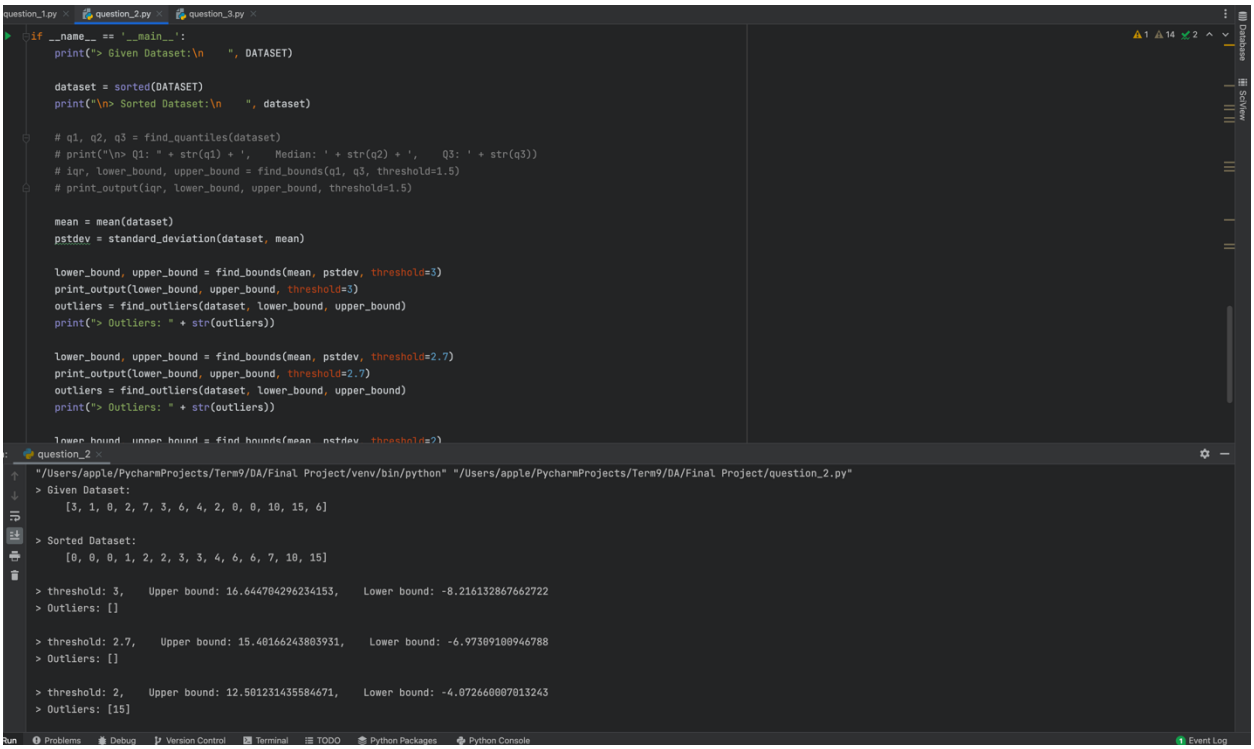

سوال ۳)

پروژه همراه با توضیحات در google colab پیاده‌سازی شده‌است که فایلش هم ضمیمه شده است.

عکس از پیاده‌سازی و گزارش پروژه در فضای colab:

افزودن کتابخانه‌های مورد استفاده

```
[122] import pandas as pd
      import random
      import matplotlib.pyplot as plt
      import numpy as np
      from numpy.linalg.linalg import norm
```

خواندن داده از فایل

```
[123] iris = pd.read_csv('iris_data.csv', names=["sepal_length", "sepal_width", "petal_length", "petal_width", "target"])
      iris
```

نمایش گرافیکی داده برحسب ویژگی طول سپال برای نمونه

```
[49] iris.plot(kind="scatter", x = 'target', y = 'sepal_length')
     plt.show()
```

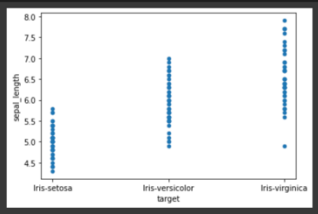

پیش‌پردازش

پیدا کردن سطرهای بدون مقدار و ناقص

```
[56] def print_nans():
         # Find and show NaNs
         print('Number of sepal_length NaNs:', len(iris[iris['sepal_length'].isna()]))
         print(iris[iris['sepal_length'].isna()])
         # print(len(df['sepal_length'].dropna()))

         # print((df['sepal_length'].isna()).where(df['sepal_length'] == True))
         # print_hi('PyCharm')

         print('\n\nNumber of sepal_width NaNs:', len(iris[iris['sepal_width'].isna()]))
         print(iris[iris['sepal_width'].isna()])

         print('\n\nNumber of petal_length NaNs:', len(iris[iris['petal_length'].isna()]))
         print(iris[iris['petal_length'].isna()])

         print('\n\nNumber of petal_width NaNs:', len(iris[iris['petal_width'].isna()]))
         print(iris[iris['petal_width'].isna()])

         print('\n\nNumber of target NaNs:', len(iris[iris['target'].isna()]))
         print(iris[iris['target'].isna()])
```

```
print_nans()
```

```
Number of sepal_length NaNs: 0
Empty DataFrame
Columns: [sepal_length, sepal_width, petal_length, petal_width, target]
Index: []


Number of sepal_width NaNs: 0
Empty DataFrame
Columns: [sepal_length, sepal_width, petal_length, petal_width, target]
Index: []


Number of petal_length NaNs: 0
Empty DataFrame
```

```
Columns: [sepal_length, sepal_width, petal_length, petal_width, target]
[57] Index: []


     Number of petal_length NaNs: 0
     Empty DataFrame
     Columns: [sepal_length, sepal_width, petal_length, petal_width, target]
     Index: []


     Number of petal_width NaNs: 0
     Empty DataFrame
     Columns: [sepal_length, sepal_width, petal_length, petal_width, target]
     Index: []


     Number of target NaNs: 0
     Empty DataFrame
     Columns: [sepal_length, sepal_width, petal_length, petal_width, target]
     Index: []
```

همانطور که می‌بینیم، تمامی سطرها مقدار دارند و سطر بدون مقدار نداریم

حذف داده‌های ناقص و بدون مقدار

```
[54] def remove_nans():
         # print(df[df.isna()])
         global iris
         print('\n\nNumber of rows = ', len(iris))
         iris = iris.dropna()
         iris.reset_index(drop=True)
         print('NaNs were removed. Number of rows = ', len(iris))
```

```
remove_nans()
```

```
Number of rows =  150
NaNs were removed. Number of rows =  150
```

همانطور که می‌بینیم، هیچ سطری تغییر نکرد زیرا تمامی سطرها مقدار دارند و سطر بدون مقدار نداریم

پیادسازی K-means

ابتدا باید به هر نمونه داده، یک کلاس را به صورت رندم اختصاص بدهیم

```
[63] def apply_clusters(nodes, number_of_clusters):
         nodes['cluster'] = nodes.apply(lambda x: random.randint(0, number_of_clusters-1), axis=1)
```

```
apply_clusters(iris, 3)
iris
```

	sepal_length	sepal_width	petal_length	petal_width	target	cluster
0	5.1	3.5	1.4	0.2	Iris-setosa	0
1	4.9	3.0	1.4	0.2	Iris-setosa	2
2	4.7	3.2	1.3	0.2	Iris-setosa	1
3	4.6	3.1	1.5	0.2	Iris-setosa	2
4	5.0	3.6	1.4	0.2	Iris-setosa	1
...	...	...	...	...	...	...
145	6.7	3.0	5.2	2.3	Iris-virginica	2
146	6.3	2.5	5.0	1.9	Iris-virginica	1
147	6.5	3.0	5.2	2.0	Iris-virginica	2
148	6.2	3.4	5.4	2.3	Iris-virginica	0
149	5.9	3.0	5.1	1.8	Iris-virginica	0

150 rows × 6 columns

با تابع زیر مراکز را آپدیت می‌کنیم. به این صورت که مرکز جدید هر دسته را برابر میانگین مقادیر آن دسته قرار می‌دهیم

```
[138] def calculate_centroids(nodes, number_of_clusters):
          means = []
```

با تابع زیر مراکز را آپدیت می‌کنیم. به این صورت که مرکز جدید هر دسته را برابر میانگین مقادیر آن دسته قرار می‌دهیم

```
[138] def calculate_centroids(nodes, number_of_clusters):
        means = []
        for i in range(number_of_clusters):
          temp_nodes = nodes.loc[nodes['cluster'] == i]
          means.append(temp_nodes.mean().iloc[0:4])
        return means
```

با این تابع، خوشه مربوط به هر داده را با نزدیکترین مرکز به آن داده بروزرسانی می‌کنیم. برای محاسبه فاصله از تفاوت مقدار فیچرها به صورت نرم شده استفاده کرده‌ایم

```
[124] def update_clusters(nodes, centroids):
        changed = False
        for index, node in nodes.iterrows():
          distances = [norm((node.iloc[0:4] - centroid).to_numpy()) for centroid in centroids]
          new_cluster = distances.index(min(distances))
          if new_cluster != node['cluster']:
             changed = True
          nodes.at[index, 'cluster'] = new_cluster
        return changed
```

در یک حلقه تا جایی که مراکز دیگر آپدیت نشوند، فرایند بروزرسانی مراکز و خوشه‌ی هر داده را تکرار می‌کنیم

```
changed = True
number_of_clusters = 3
apply_clusters(iris, number_of_clusters)
itteration = 0

while changed:
  centroids = calculate_centroids(iris, number_of_clusters)
  changed = update_clusters(iris, centroids)
  itteration += 1

print(f'Centroids: {centroids}')
```

```
[124]     nodes.at[index, 'cluster'] = new_cluster
        return changed
```

در یک حلقه تا جایی که مراکز دیگر آپدیت نشوند، فرایند بروزرسانی مراکز و خوشه‌ی هر داده را تکرار می‌کنیم

```
changed = True
number_of_clusters = 3
apply_clusters(iris, number_of_clusters)
itteration = 0

while changed:
  centroids = calculate_centroids(iris, number_of_clusters)
  changed = update_clusters(iris, centroids)
  itteration += 1

print(f'Centroids: {centroids}')

print(f'Number of Itterations: {itteration}')
```

```
<ipython-input-138-875ab929879a>:5: FutureWarning: Dropping of nuisance columns in DataFrame reductions (with 'numeric_only=None') is deprecated; in a future version this will raise Type
  means.append(temp_nodes.mean().iloc[0:4])
Centroids: [sepal_length    5.883607
sepal_width     2.740984
petal_length    4.388525
petal_width     1.434426
dtype: float64, sepal_length    6.853846
sepal_width     3.076923
petal_length    5.715385
petal_width     2.053846
dtype: float64, sepal_length    5.006
sepal_width     3.418
petal_length    1.464
petal_width     0.244
dtype: float64]
Number of Itterations: 13
```

مراکز نهایی چاپ شده‌اند. هم چنین می‌بینی که در ۱۱ پیمایش به شرط توقف میرسیم و دیگر مراکز و خوشه‌ی داده‌ها تغییر نمی‌کند.

مصورسازی

مصورسازی

نمایش گرافیکی پراکندگی داده‌ها برحسب دو ویژگی که خوشه‌ها با ۳ رنگ نمایش داده‌شده‌اند. پس داده‌های همرنگ مربوط به یک خوشه هستند

```
[133] plt.scatter(x = iris['petal_width'], y = iris['petal_length'], c=iris['cluster'])
      plt.show()
```

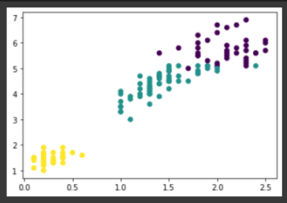

```
plt.scatter(x = iris['sepal_width'], y = iris['sepal_length'], c=iris['cluster'])
plt.show()
```

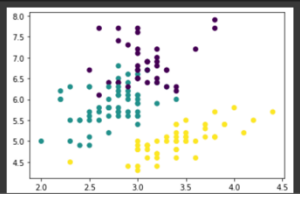

```
[134]
```

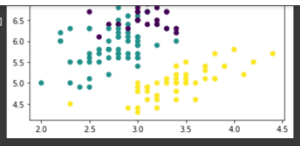

```
[135] plt.scatter(x = iris['petal_width'], y = iris['sepal_length'], c=iris['cluster'])
      plt.show()
```

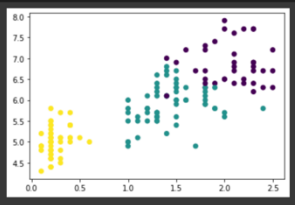

```
plt.scatter(x = iris['sepal_width'], y = iris['petal_length'], c=iris['cluster'])
plt.show()
```